

UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE INFORMÁTICA E ESTATÍSTICA
CIÊNCIA DA COMPUTAÇÃO

Tiago Oliveira da Luz

**Adaptação de Modelos de Linguagem Multimodal para geração de anotação
meteorológica em formato METAR**

Florianópolis
2024

Tiago Oliveira da Luz

Adaptação de Modelos de Linguagem Multimodal para geração de anotação meteorológica em formato METAR

Trabalho de Conclusão de Curso submetido ao
Curso de Graduação em Ciência da Computa-
ção do Centro Tecnológico da Universidade
Federal de Santa Catarina como requisito para
obtenção do título de Bacharel em Ciência da
Computação.

Orientadora: Prof. Dr. Aldo Von Wangenheim

Coorientadora: Juliana Marian Arrais

Florianópolis

2024

FOLHA DE APROVAÇÃO DE PROPOSTA DE TCC

Acadêmico(s)	Tiago Oliveira da Luz
Título do trabalho (subtítulo)	Adaptação de Modelos de Linguagem Multimodal para geração de anotação meteorológica em formato METAR
Curso	Ciência da Computação/INE/UFSC
Área de Concentração	Inteligência Artificial

Instruções para preenchimento pelo **ORIENTADOR DO TRABALHO**:

- Para cada critério avaliado, assinale um X na coluna SIM apenas se considerado aprovado. Caso contrário, indique as alterações necessárias na coluna Observação.

Critérios	Aprovado				Observação
	Sim	Parcial	Não	Não se aplica	
1. O trabalho é adequado para um TCC no CCO/SIN (relevância / abrangência)?					
2. O título do trabalho é adequado?					
3. O tema de pesquisa está claramente descrito?					
4. O problema/hipóteses de pesquisa do trabalho está claramente identificado?					
5. A relevância da pesquisa é justificada?					
6. Os objetivos descrevem completa e claramente o que se pretende alcançar neste trabalho?					
7. É definido o método a ser adotado no trabalho? O método condiz com os objetivos e é adequado para um TCC?					
8. Foi definido um cronograma coerente com o método definido (indicando todas as atividades) e com as datas das entregas (p.ex. Projeto I, II, Defesa)?					
9. Foram identificados custos relativos à execução deste trabalho (se houver)? Haverá financiamento para estes custos?					
10. Foram identificados todos os envolvidos neste trabalho?					
11. As formas de comunicação foram definidas (ex: horários para orientação)?					
12. Riscos potenciais que podem causar desvios do plano foram identificados?					
13. Caso o TCC envolva a produção de um software ou outro tipo de produto e seja desenvolvido também como uma atividade realizada numa empresa ou laboratório, consta da proposta uma declaração (Anexo 3) de ciência e concordância com a entrega do código fonte e/ou documentação produzidos?					

Avaliação	<input type="checkbox"/> Aprovado		<input type="checkbox"/> Não Aprovado
Professor Responsável	Aldo Von Wangenheim	04/11/24	
Orientador Externo	Juliana Marian Arrais	12/11/24	

RESUMO

A geração de anotações meteorológicas precisas é fundamental para setores como a aviação. Pequenos aeródromos e áreas remotas enfrentam limitações significativas na coleta de dados atmosféricos devido à ausência de sistemas automatizados, como AWOS e ASOS, e à dependência de métodos manuais e dados de aeroportos distantes. Para abordar essas lacunas, este projeto propõe o uso de Modelos de Linguagem Multimodal (MLLM) integrados a câmeras terrestres de baixo custo para gerar automaticamente relatórios METAR. O estudo inclui a construção de um dataset de pares imagem/METAR, análise de modelos MLLM pré-treinados, fine-tuning dos modelos selecionados e realização de experimentos para avaliar sua eficácia. A metodologia visa fornecer uma solução automatizada e confiável para o monitoramento atmosférico contínuo, superando as limitações dos métodos tradicionais e oferecendo benefícios significativos em precisão, acessibilidade e aplicabilidade operacional.

Palavras-chave: MLLM. SOTA. Fine-Tuning. *METAR*. *weather nowcasting*.

SUMÁRIO

1	INTRODUÇÃO	5
2	OBJETIVOS	7
2.1	OBJETIVO GERAL	7
2.2	OBJETIVOS ESPECÍFICOS	7
3	ESCOPO	8
3.1	CRITÉRIOS DE ACEITAÇÃO	8
3.2	ENTREGAS DO PROJETO	9
3.3	RESTRICÇÕES	9
3.4	PREMISSAS	10
4	METODOLOGIA DE PESQUISA	11
4.1	CRIAÇÃO E VALIDAÇÃO DO DATASET	11
4.2	ANÁLISE PRELIMINAR DOS MODELOS	11
4.3	TREINAMENTO DOS MODELOS (FINE-TUNING)	11
4.4	REALIZAÇÃO DE EXPERIMENTOS E AVALIAÇÃO DOS RESULTADOS	11
5	CRONOGRAMA	12
6	CUSTOS	13
7	RECURSOS HUMANOS	14
8	COMUNICAÇÃO	15
9	RISCOS	16
	REFERÊNCIAS	17

1 INTRODUÇÃO

A observação da cobertura de nuvens e o monitoramento preciso de dados meteorológicos, tanto a curto quanto a longo prazo, são de grande importância para diversas áreas, como por exemplo, na aviação (SOMAN et al., 2010). Na navegação aérea, é importante que pilotos e postos de controle tenham informações relevantes e atualizadas das condições de tempo e clima em uma região. Para isso, existem diversos formatos de representação de informações climáticas, sendo o mais utilizado entre eles o informe meteorológico regular de aeródromo, conhecido como Meteorological Aerodrome Report (METAR). No entanto, pequenos aeródromos e localidades remotas frequentemente carecem de sistemas automatizados de observação meteorológica, dependendo de métodos manuais sujeitos a erros ou de dados provenientes de locais distantes, que podem não refletir as condições locais. Este projeto busca resolver esse problema integrando câmeras terrestres de baixo custo a Modelos de Linguagem Multimodal (MLLMs) para gerar relatórios meteorológicos automatizados, como o METAR. A proposta inclui a construção de um dataset de imagens terrestres do céu associadas a anotações METAR e o ajuste de modelos MLLMs por meio de fine-tuning, visando melhorar a precisão e a confiabilidade das informações meteorológicas em áreas com infraestrutura limitada.

O METAR fornece uma visão detalhada das condições atmosféricas em aeroportos, incluindo vento, visibilidade, cobertura de nuvens, fenômenos meteorológicos, temperatura e pressão atmosférica. Em aeroportos de grande porte, o METAR é gerado automaticamente por sistemas meteorológicos avançados, como o Automated Weather Observing System (AWOS) e o Automated Surface Observing System (ASOS), que monitoram continuamente as condições atmosféricas por meio de sensores especializados. Esses sistemas, altamente precisos e complexos, demandam instalação, manutenção e calibração frequentes, além de técnicos especializados (YANG et al., 2018). Essa infraestrutura sofisticada e cara torna os sistemas AWOS e ASOS inacessíveis para pequenos aeródromos e aeroclubes. Especialmente em áreas remotas, a ausência de sistemas automatizados de observação meteorológica representa uma lacuna crítica no monitoramento contínuo das condições atmosféricas. Esses locais frequentemente dependem de observações manuais realizadas por operadores treinados ou de dados meteorológicos provenientes de aeroportos maiores e mais distantes.

As observações meteorológicas manuais envolvem estimativas feitas por operadores que são muitas vezes subjetivas e limitadas pela experiência do observador, além de dependerem de instrumentos menos precisos e de uma frequência de atualização menor. Isso resulta em uma menor consistência e confiabilidade dos dados quando comparados aos métodos automáticos (YANG et al., 2018).

Utilizar dados meteorológicos de aeroportos mais distantes como fonte alternativa também apresenta limitações. A variabilidade das condições climáticas, mesmo em curtas distâncias, pode ser significativa, levando a discrepâncias que afetam a precisão das previsões locais. Isso pode impactar negativamente não apenas a segurança e a eficiência na aviação, mas também outros setores dependentes de previsões meteorológicas precisas, como a agricultura e a

geração de energia renovável (WHITE; FINNEY, 2005).

Nesse cenário, o uso de câmeras de baixo custo integradas a modelos de Inteligência Artificial, em particular técnicas de Visão Computacional e Grandes Modelos de Linguagem Multimodal (MLLMs), surge como uma alternativa promissora. Nos últimos anos, pesquisas têm explorado soluções para problemas meteorológicos por meio da análise de imagens de nuvens, utilizando desde abordagens clássicas de Visão Computacional (MESIN, 2011) até técnicas mais avançadas de Deep Learning (CERENTINI et al., 2024) (ZHANG et al., 2022), como apontado por (ARRAIS et al., 2024). Contudo, a geração automática de relatórios METAR, que são utilizados para descrever condições atmosféricas em aeroportos, a partir de dados visuais ainda é um algo pouco explorado na literatura.

Este estudo busca investigar o uso de MLLMs para a geração automatizada de relatórios meteorológicos a partir de dados visuais, explorando técnicas avançadas de aprendizado de máquina. O objetivo é desenvolver uma metodologia que aumente a precisão e a confiabilidade das informações meteorológicas, apoiando decisões mais seguras e eficientes em setores como aviação, agricultura e energia renovável.

2 OBJETIVOS

2.1 OBJETIVO GERAL

Este estudo visa explorar o potencial dos MLLMs para a geração de anotações METAR a partir de imagens terrestres do céu, por meio de um processo de fine-tuning utilizando um dataset específico de pares imagem/METAR. A proposta de integrar câmeras locais com esses modelos visa oferecer uma solução automatizada para monitoramento contínuo e análise das condições atmosféricas, substituindo a subjetividade das observações manuais e mitigando as limitações dos dados obtidos de locais distantes. Dessa forma, busca-se desenvolver uma metodologia que aumente a precisão e a confiabilidade das anotações meteorológicas, contribuindo para decisões mais informadas e seguras na aviação e em outros setores críticos que dependem de previsões climáticas precisas.

2.2 OBJETIVOS ESPECÍFICOS

- Coletar e construir um dataset composto por pares de imagens terrestres do céu e suas respectivas anotações METAR, para ser utilizado no processo de fine-tuning dos modelos;
- Identificar e selecionar os modelos MLLMs mais adequados para o fine-tuning, baseando-se em seu desempenho e capacidade prévio de lidar com dados meteorológicos;
- Realizar o fine-tuning de uma MLLM utilizando o dataset criado;
- Avaliar e comparar o desempenho dos modelos MLLMs após o fine-tuning com suas versões pré-treinadas, considerando métricas de precisão e consistência na geração de anotações METAR;
- Analisar as limitações e identificar possíveis melhorias nos MLLMs, com foco na capacidade dos MLLMs na geração de METARs.

3 ESCOPO

O escopo deste projeto é delineado para abordar de forma sistemática a aplicação de MLLMs na tarefa de geração de anotações METAR a partir de imagens terrestres do céu. O trabalho será estruturado em etapas bem definidas, iniciando pela criação e validação de um dataset especializado. Esse dataset será composto por pares de imagens de câmeras posicionadas em solo e suas respectivas descrições METAR, visando capturar uma ampla diversidade de condições climáticas. Durante a construção do dataset, é possível que múltiplas imagens de diferentes câmeras sejam associadas a um mesmo relatório METAR para aumentar a representatividade dos dados coletados.

Na sequência, será realizada uma análise preliminar de modelos MLLMs pré-treinados, com o objetivo de selecionar aqueles que apresentam maior potencial para compreender informações meteorológicas. Essa seleção será orientada pela capacidade dos modelos em lidar com conceitos meteorológicos já existentes em seu aprendizado prévio, o que pode reduzir a necessidade de um grande volume de dados para o fine-tuning.

O processo de fine-tuning será então conduzido utilizando o dataset desenvolvido, ajustando os modelos escolhidos para aprimorar sua capacidade de gerar descrições METAR com precisão e consistência. Devido às limitações do projeto, a análise de hiperparâmetros será limitada a ajustes básicos, evitando uma exploração extensiva e complexa.

Por fim, uma série de experimentos será realizada para avaliar o desempenho dos modelos antes e após o fine-tuning. Os resultados serão analisados com base em métricas quantitativas de precisão e consistência, verificando a eficácia da metodologia proposta e identificando possíveis limitações e áreas para melhorias futuras.

É importante ressaltar que o projeto se concentrará na utilização de imagens terrestres, excluindo o uso de dados de satélites ou radares. Além disso, não será realizada uma análise de viabilidade econômica ou estudo de custo-benefício para uma implementação em larga escala, focando apenas nos aspectos técnicos e de desempenho da solução proposta. A infraestrutura de treinamento será limitada aos recursos locais disponíveis, sem a utilização de serviços comerciais de nuvem, o que implica uma dependência da capacidade computacional fornecida pela UFSC.

3.1 CRITÉRIOS DE ACEITAÇÃO

- Obter a aprovação do projeto final por parte da banca examinadora;
- Garantir a conformidade das entregas com os prazos estabelecidos;
- Adequar as produções textuais desenvolvidas às normas da ABNT e aos padrões exigidos pela UFSC;
- Atender aos objetivos propostos de forma completa e satisfatória;

- Construir dataset com volume e qualidades de dados adequados para os objetivos propostos;
- Apresentar uma análise preliminar dos modelos escolhidos e suas capacidades de compreensão de dados meteorológicos;
- Realizar o fine-tuning dos modelos selecionados com sucesso, sem falhas no processo de ajuste;
- Demonstrar um desempenho aceitável na geração de anotações METAR, com métricas de acurácia definidas;
- Documentar os resultados, limitações do trabalho e sugestões de trabalhos futuros.

3.2 ENTREGAS DO PROJETO

- O documento correspondente à entrega do Trabalho de Conclusão de Curso I (INE5433), contendo toda a fundamentação teórica base do relatório;
- Documento final do Trabalho de Conclusão de Curso II (INE5434), incluindo o relatório com links para o dataset, modelo treinado e os códigos utilizados;
- Modelo de MLLM treinado para geração de descrição METAR;
- Dataset desenvolvido e utilizado durante o projeto, contendo pares de imagens e anotações METAR.

3.3 RESTRIÇÕES

- Os documentos devem seguir as normas da ABNT;
- As entregas dos documentos devem respeitar o calendário exigido pela UFSC;
- Não será realizada análise extensiva de hiperparâmetros durante o fine-tuning dos modelos;
- O dataset será composto apenas por imagens de câmeras terrestres, sem o uso de dados de satélite ou de radar;
- Limitações de tempo e recursos financeiros poderão restringir o tamanho do dataset e o número de experimentos realizados.

3.4 PREMISSAS

- Disponibilidade de pesquisas científicas relevantes que fundamentem a criação do relatório;
- Uso de bibliotecas de código aberto para manipulação de dados para construção do dataset e realização do fine-tuning dos modelos;
- Acesso contínuo a um computador portátil com internet para redigir o relatório e realizar experimentos;
- Disponibilidade da infraestrutura de GPUs da UFSC para a execução das sessões de treinamento dos modelos.

4 METODOLOGIA DE PESQUISA

A metodologia deste projeto será estruturada em quatro etapas principais: criação e validação do dataset, análise preliminar dos modelos para fine-tuning, treinamento dos modelos escolhidos e realização de experimentos para avaliação dos resultados. Cada uma dessas etapas será descrita detalhadamente a seguir.

4.1 CRIAÇÃO E VALIDAÇÃO DO DATASET

Nesta fase, será realizada a construção de um dataset de pares imagem/METAR para a realização dos treinamentos, sendo cada imagem associada à sua descrição METAR correspondente. Possivelmente por questão de limites de tempo, o dataset (ARRAIS et al., 2023) será utilizado como base para a realização desse projeto. A validação do dataset será realizada para assegurar que as imagens e as descrições METAR estejam corretamente associadas e representem uma diversidade de condições climáticas.

4.2 ANÁLISE PRELIMINAR DOS MODELOS

Nesta etapa, será feita uma análise de modelos de linguagem multimodal (MLLMs) já pré-treinados, para selecionar aqueles com maior potencial para compreender dados meteorológicos. O foco será identificar modelos que possuam capacidade de generalização suficiente para reduzir a quantidade de dados necessária para o fine-tuning. A análise incluirá a avaliação de características como a arquitetura do modelo, dataset de treinamento original e desempenho em tarefas similares.

4.3 TREINAMENTO DOS MODELOS (FINE-TUNING)

Após a seleção, os modelos escolhidos passarão pelo processo de fine-tuning utilizando o dataset criado. O objetivo é adaptar os modelos para a tarefa específica de geração de anotações METAR, ajustando seus parâmetros com base nas novas informações do dataset. O ajuste de hiperparâmetros será realizado de forma básica, sem uma análise extensiva, devido às restrições definidas no escopo do projeto.

4.4 REALIZAÇÃO DE EXPERIMENTOS E AVALIAÇÃO DOS RESULTADOS

Na fase final, serão conduzidos experimentos para avaliar a capacidade dos modelos de gerar descrições METAR precisas. O desempenho será medido por meio de métricas quantitativas que avaliem a precisão e a consistência das anotações geradas antes e após o fine-tuning. Os resultados serão analisados para determinar a eficácia da metodologia e identificar possíveis limitações e melhorias futuras.

[illegible]

6 CUSTOS

Item	Quantidade	Valor unitário (R\$)	Valor Total (R\$)
Material permanente			
Notebook	1	3.000,00	3.000,00
Outros recursos e serviços			
Acesso a servidor	20	10,00	200,00
TOTAL			3.200,00

7 RECURSOS HUMANOS

Nome	Função
Tiago Oliveira da Luz	Autor
Aldo Von Wangenheim	Orientador e professor responsável
Juliana Marian Arrais	Coorientadora
A definir	Membro da banca
A definir	Membro da banca

8 COMUNICAÇÃO

O que precisa ser comunicado	Por quem	Para quem	Melhor forma de comunicação	Quando e com que frequência
Envio do relatório de Projeto I	Autor	Banca	Via site de projetos	Prazo da entrega 25/11/2024
Envio do rascunho do TCC	Autor	Banca	Via site de projetos	Prazo da entrega 09/06/2025
Apresentação do TCC	Autor	Banca	Web conferência	23/06/2025
Entrega da versão final	Autor	Banca	Via site de projetos	Prazo da entrega 07/07/2025
Status do projeto	Autor	Orientador e coorientadora	Reunião remota	Quinzenalmente

9 RISCOS

Risco	Probabilidade	Impacto	Prioridade	Estratégia de resposta	Ações de prevenção
Perda de dados	Baixa	Alto	Média	Recuperação de backup	Documentos salvos no Google Drive e código no GitHub
Alteração do calendário acadêmico em função de greve	Média	Médio	Média	Reavaliação do cronograma	Não se aplica
Eficiência insatisfatória do modelo	Alta	Alta	Alta	Analisar e alterar implementação	Estudar processo de fine-tuning e parametrização de modelos
Chuvas fortes e alagamento na UFSC	Média	Baixo	Baixa	Não se aplica	Manter meios de comunicação remotos
Dataset insuficiente para fine-tuning	Média	Alto	Média	Reavaliar escopo do projeto	Realizar revisão do dataset e realizar teste preliminares

REFERÊNCIAS

ARRAIS, J. M. et al. **Dataset Clouds-1500**. 2023.

ARRAIS, J. M. et al. Systematic review on ground-based cloud tracking methods for photovoltaics nowcasting. **American Journal of Climate Change**, Scientific Research Publishing, v. 13, n. 3, p. 452–476, 2024.

CERENTINI, A. et al. Enhancing semantic segmentation of cloud images captured with horizon-oriented cameras. **International Journal of Advanced Remote Sensing and GIS**, v. 12, n. 1, p. 3531–3544, 2024.

MESIN, L. Short range tracking of rainy clouds by multi-image flow processing of x-band radar data. **EURASIP Journal on Advances in Signal Processing**, Springer, v. 2011, p. 1–14, 2011.

SOMAN, S. S. et al. A review of wind power and wind speed forecasting methods with different time horizons. In: IEEE. **North American power symposium 2010**. [S.l.], 2010. p. 1–8.

WHITE, L.; FINNEY, J. A descriptive survey of meteorological observing systems in mississippi. **J. of Miss. Acad. of Sci**, v. 50, p. 213–223, 2005.

YANG, X. et al. Updating and augmenting weather data for pavement mechanistic-empirical design using asos/awos database in michigan. **International Journal of Pavement Engineering**, Taylor & Francis, v. 19, n. 11, p. 1025–1033, 2018.

ZHANG, X. et al. Multi-modal spatio-temporal meteorological forecasting with deep neural network. **ISPRS Journal of Photogrammetry and Remote Sensing**, Elsevier, v. 188, p. 380–393, 2022.